

Econometria I: Material de apoio

1. Econometria e estrutura dos dados

A **econometria** combina teoria econômica, estatística e matemática para analisar dados. Com ela, podemos quantificar relações entre variáveis, testar hipóteses e produzir previsões. A qualidade das conclusões depende tanto do modelo quanto dos dados e das hipóteses que conectam ambos.

Analisaremos os tipos de dados: Com dados de **cross-section**, ou **corte transversal**: observações de várias unidades — pessoas, empresas, países ou famílias — em um mesmo período. Isso permite comparar diferenças entre unidades naquele momento.

Já dados em formato de uma **série temporal** acompanha uma unidade ou agregado ao longo de vários períodos. Já os **dados em painel** combinam unidades e tempo, acompanhando várias unidades ao longo de diferentes períodos.

2. Regressão linear simples

Na regressão simples, usamos uma variável explicativa **X** para estudar uma variável de interesse **Y**. A forma populacional do modelo é:

$$Y_i = \beta_0 + \beta_1 X_i + u_i$$

Os elementos da fórmula são:

- **Y_i** : valor da variável dependente na observação i . É o resultado que queremos explicar.
- **X_i** : valor da variável explicativa na observação i .
- **β_0** : intercepto. É o valor médio previsto de Y quando $X = 0$, sob a hipótese de média condicional zero do erro.
- **β_1** : inclinação da reta. Descreve quanto Y varia, em média, quando X aumenta uma unidade.
- **u_i** : erro do modelo. Reúne os fatores que influenciam Y , mas não aparecem explicitamente na regressão.
- **i** : índice que identifica cada observação.

Por exemplo, se Y for o valor da gorjeta e X o total da conta, a pergunta é se contas maiores estão associadas a gorjetas maiores.


Suponha a relação:

$$\text{Gorjeta prevista} = 0,920 + 0,105 \times \text{valor da conta}$$

Um aumento de uma unidade no valor da conta está associado a aproximadamente **0,105 unidade a mais de gorjeta prevista**, em média.

O intercepto é a previsão matemática quando a conta vale zero. Ele pode não ter interpretação econômica útil, especialmente quando esse valor está fora da faixa observada

Exemplo visual



3. Estimação por Mínimos Quadrados Ordinários

Na prática, não observamos toda a população. Temos uma amostra e usamos seus dados para estimar os parâmetros desconhecidos β_0 e β_1 .

O método apresentado é o **Mínimos Quadrados Ordinários — MQO**, que escolhe a reta que minimiza a soma dos resíduos ao quadrado.

3.1. O que o MQO minimiza

Minimizar, em relação a β_0 e β_1 :

$$\sum_{i=1}^n (Y_i - \beta_0 - \beta_1 X_i)^2$$

Nessa expressão:

- **n**: número de observações da amostra.
- $\sum_{i=1}^n$: indica que somamos a expressão para todas as observações, de $i = 1$ até $i = n$.
- **Y_i e X_i** : valores observados da unidade i .
- **β_0 e β_1** : valores candidatos para os parâmetros.
- **$Y_i - \beta_0 - \beta_1 X_i$** : diferença entre o valor observado de Y e o valor previsto pela reta candidata.

O MQO escolhe os valores dos parâmetros que tornam essa soma a menor possível.

Ao elevar as diferenças ao quadrado, evita-se que erros positivos e negativos se cancelem e dá-se maior peso a erros grandes.

3.2. Fórmulas dos coeficientes estimados

Na regressão simples, as soluções podem ser escritas diretamente como:

$$\beta_1 = [\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})] / [\sum_{i=1}^n (X_i - \bar{X})^2]$$

$$\beta_0 = \bar{Y} - \beta_1 \bar{X}$$

Os símbolos representam:

- β_1 : inclinação estimada com os dados da amostra.
- β_0 : intercepto estimado com os dados da amostra.
- $\bar{X}$: média amostral de X.
- $\bar{Y}$: média amostral de Y.
- $X_i - \bar{X}$: distância de cada valor de X em relação à média de X.
- $Y_i - \bar{Y}$: distância de cada valor de Y em relação à média de Y.
- **Chapéu sobre o símbolo**: indica uma estimativa calculada na amostra.

A inclinação estimada β_1 equivale à **covariância amostral entre X e Y dividida pela variância amostral de X**, desde que ambas sejam calculadas com a mesma convenção de divisor.

O intercepto β_0 posiciona a reta de modo que ela passe pelo ponto das médias ($\bar{X}, \bar{Y}$).

3.3. Valores previstos e resíduos

O resíduo de uma observação é a diferença entre o valor observado e o valor previsto pela reta estimada:

$$e_i = Y_i - \hat{Y}_i$$

O valor previsto é:

$$\hat{Y}_i = \beta_0 + \beta_1 X_i$$

Nessas expressões:

- e_i , também representado por $\hat{u}_i$, é o resíduo estimado da observação i.
- Y_i : valor observado.
- $\hat{Y}_i$: valor ajustado, isto é, a previsão da reta estimada.

A distinção é importante: u_i é o **erro não observado do modelo populacional**; e_i é o **resíduo calculado depois de estimarmos o modelo**.

MQO encontra a melhor reta dentro do critério de minimizar erros quadráticos, mas isso sozinho não prova que X causa Y.

4. Qualidade de ajuste: R^2

O coeficiente de determinação, R^2 , resume a parcela da variação amostral de Y que é explicada pelo modelo.

Um R^2 de **0,60**, por exemplo, indica que **60% da variação observada de Y na amostra é contabilizada pela regressão**. O restante fica associado a fatores não incluídos e a variações não explicadas.

4.1. Soma explicada e soma total dos quadrados

A fórmula apresentada no material é:

$$R^2 = ESS / TSS$$

Em que:

$$ESS = \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2$$

$$TSS = \sum_{i=1}^n (Y_i - \bar{Y})^2$$

Os elementos representam:

- **ESS**: soma explicada dos quadrados. Mede quanto os valores ajustados $\hat{Y}_i$ variam em torno da média $\bar{Y}$.
- **TSS**: soma total dos quadrados. Mede quanto os valores observados Y_i variam em torno da média $\bar{Y}$.
- $\hat{Y}_i$: valor previsto pela regressão.
- Y_i : valor observado.
- $\bar{Y}$: média amostral de Y.

Assim, R^2 é a fração da variação total contabilizada pela parte explicada pelo modelo.

4.2. Soma dos quadrados dos resíduos

A soma dos quadrados dos resíduos é:

$$SSR = \sum_{i=1}^n \hat{u}_i^2$$

Aqui:

- **SSR**: soma dos resíduos ao quadrado, usando a nomenclatura do notebook.
- $\hat{u}_i$: resíduo estimado da observação i.

Com MQO e intercepto, vale a decomposição:

$$TSS = ESS + SSR$$

Por isso, uma forma equivalente de calcular R^2 é:

$$R^2 = 1 - SSR / TSS$$

Quanto menor a parcela da variação total que permanece nos resíduos, maior o R^2 .

R^2 mede ajuste dentro da amostra. Ele não demonstra causalidade, não garante que o modelo esteja bem especificado e tampouco assegura previsões precisas fora da amostra.

Um modelo pode ter R^2 alto e ainda sofrer de variável omitida, causalidade reversa ou outras falhas.

4.3. R^2 ajustado

Na regressão múltipla, adicionar variáveis explicativas nunca reduz o R^2 comum, quando se mantém a mesma amostra e a mesma variável dependente, mesmo que essas variáveis contribuam pouco.

Por isso, também se usa o **R^2 ajustado**, que leva em conta o número de regressores e penaliza inclusões que pouco melhoram o ajuste.

Sua fórmula é:

$$\hat{R}^2 = 1 - [(n - 1) / (n - k - 1)] \times (SSR / TSS)$$

Os símbolos representam:

- **$\hat{R}^2$** : R^2 ajustado.
- **n**: número de observações.
- **k**: número de variáveis explicativas, sem contar o intercepto.
- **SSR**: soma dos resíduos ao quadrado.
- **TSS**: soma total dos quadrados.
- **n - k - 1**: graus de liberdade restantes depois de estimar k coeficientes das variáveis explicativas e um intercepto.

O ajuste considera quantos graus de liberdade restam depois de estimar os coeficientes, penalizando regressores que não melhoram suficientemente o ajuste.

Ele ajuda na comparação entre modelos com quantidades diferentes de variáveis, mas não substitui a avaliação teórica e estatística.

5. Hipóteses e cuidados de interpretação

As hipóteses ajudam a entender quando a reta e a inferência estatística são confiáveis. Elas descrevem como os dados devem se comportar para que os resultados possam ser interpretados.

5.1. Linearidade

O modelo representa a relação média entre X e Y por uma linha reta.

Gráficos podem ajudar a avaliar se essa aproximação parece razoável. Uma relação curva pode exigir transformações ou outra especificação.

5.2. Independência das observações

Uma observação não deve carregar dependência não considerada em relação às demais.

Se, por exemplo, erros de pessoas do mesmo grupo estiverem correlacionados, os erros-padrão e testes usuais podem ser inadequados.

5.3. Exogeneidade

A hipótese de média condicional zero do erro é:

$$E(u_i | X_i) = 0$$

Nessa expressão:

- **E**: esperança, ou valor médio.
- **u_i** : erro do modelo.
- **| X_i** : indica que estamos condicionando ao valor de X_i .

Em termos intuitivos, a média do erro entre observações com determinado valor de X deve ser zero.

Se fatores não observados que afetam Y também estiverem correlacionados com X, o coeficiente estimado pode ficar enviesado. Essa hipótese é central para a interpretação dos coeficientes.

5.4. Homoscedasticidade e heterocedasticidade

A homoscedasticidade pode ser representada por:

$$\text{Var}(u_i | X_i) = \sigma^2$$

Os elementos representam:

- **$\text{Var}(u_i | X_i)$** : variância do erro entre observações que têm determinado valor de X_i .
- **σ^2** : uma variância constante.

A hipótese exige que a dispersão dos erros seja a mesma para os diferentes valores de X.

Quando a variância muda conforme X, temos **heterocedasticidade**:


$\text{Var}(u_i | X_i)$ não é constante

Sob exogeneidade, a heterocedasticidade não torna automaticamente os coeficientes MQO enviesados, mas pode comprometer os erros-padrão usuais, os testes e a eficiência do MQO.

Erros-padrão robustos permitem fazer inferência mais adequada. Transformações podem ajudar em certos casos, desde que tenham justificativa.

Na aula que vocês tiveram, comentamos sobre gráficos de resíduos e testes como **Breusch–Pagan** e **White** para investigar heterocedasticidade.

Um gráfico é uma ferramenta de diagnóstico, não uma prova definitiva. A escolha de ajustes deve considerar a pergunta econômica e a estrutura dos dados.



6. Regressão múltipla e interpretação “mantendo os demais fatores constantes”

A regressão múltipla inclui duas ou mais variáveis explicativas:

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \dots + \beta_k X_{ki} + u_i$$

Nessa expressão:


- Y_i : variável dependente da observação i .
- $X_{1i}, X_{2i}, \dots, X_{ki}$: valores das variáveis explicativas da observação i .
- β_0 : intercepto.
- $\beta_1, \beta_2, \dots, \beta_k$: coeficientes das respectivas variáveis explicativas.
- k : número de regressores.
- u_i : fatores que influenciam Y e não aparecem explicitamente no modelo.

Por exemplo, na regressão simples, tínhamos: **Gorjeta prevista = $\beta_0 + \beta_1 \cdot \text{Valor da conta} + u$** .

Na regressão múltipla, podemos adicionar outra variável, por exemplo, “female”:

$$\text{Gorjeta prevista} = \beta_0 + \beta_1 \cdot \text{Valor da conta} + \beta_2 \cdot \text{female} + u$$

Suponha que o modelo estimou: **Gorjeta prevista = $1,2 + 0,15(\text{Valor da conta}) + 0,6(\text{female})$**



6.1. Estimação por MQO

Para dois regressores, X e Z, o critério MQO correspondente é:

Minimizar, em relação a β_0 , β_1 e β_2 :

$$\sum_{i=1}^n (Y_i - \beta_0 - \beta_1 X_i - \beta_2 Z_i)^2$$

No caso geral, com k variáveis explicativas, minimiza-se:

$$\sum_{i=1}^n (Y_i - \beta_0 - \beta_1 X_{i1} - \dots - \beta_k X_{ik})^2$$

O objetivo continua sendo escolher os coeficientes que tornam a soma dos resíduos ao quadrado a menor possível.

6.2. Interpretação dos coeficientes

O objetivo é relacionar Y a vários fatores ao mesmo tempo. Por exemplo, ao estudar salários, pode-se incluir educação, experiência e horas trabalhadas.

O coeficiente β_1 expressa a variação prevista em Y associada a uma unidade adicional de X_1 , **mantendo constantes as demais variáveis incluídas**.

Essa expressão compara observações semelhantes nos outros fatores do modelo. Ela não significa que, na realidade, os demais fatores sejam literalmente fixos.

A regressão múltipla pode reduzir o problema de atribuir a uma variável diferenças que estão ligadas a outras características observáveis.

Ainda assim, incluir mais controles não resolve automaticamente fatores não observados, erros de medida, seleção da amostra ou causalidade reversa. A interpretação causal exige hipóteses e desenho de pesquisa apropriados.

7. Viés de variável omitida

O **viés de variável omitida** surge quando excluímos do modelo um fator relevante para Y que também está relacionado a uma variável explicativa incluída.

Nesse caso, a associação da variável omitida pode ser parcialmente atribuída ao regressor que permaneceu no modelo.

Exemplo: suponha que educação e experiência influenciem o salário. Se estimarmos salário apenas em função da educação, e experiência também estiver associada aos anos de estudo, parte da relação entre experiência e salário poderá ser confundida com o coeficiente de educação.

O sinal e o tamanho do viés dependem de duas coisas:

- Do efeito da variável esquecida sobre Y.
- Da relação entre ela e o regressor incluído.

7.1. Expressão do viés

Uma forma algébrica de resumir o caso com uma variável omitida Z é partir do modelo verdadeiro:

$$Y_i = \beta_0 + \beta_1 X_i + \beta_2 Z_i + u_i$$

Ao omitir Z, a expressão populacional do viés no coeficiente de X é:

$$\text{Viés} = \beta_2 \times \text{Cov}(X, Z) / \text{Var}(X)$$

Os elementos representam:

- β_2 : efeito de Z sobre Y no modelo completo.
- **Cov(X, Z)**: covariância entre X e Z. Indica como as duas variáveis variam conjuntamente.
- **Var(X)**: variância de X.
- **Z**: variável relevante que foi omitida.

O viés tem o sinal do produto: depende simultaneamente do efeito de Z e de como Z se relaciona com X.

Assim, não basta dizer que uma variável foi omitida para saber se o viés é positivo ou negativo.

Se o fator omitido afeta Y, mas não tem relação com X, ele tende a aumentar a parte não explicada, sem necessariamente enviesar o coeficiente de X.

A correlação entre o fator omitido e X é que faz o efeito “vazar” para o coeficiente estimado.

8. Variáveis binárias — dummies

Uma variável binária assume dois valores, geralmente **0 e 1**. Ela permite incluir categorias qualitativas na regressão.

Por exemplo, pode-se definir:

- **female = 1**: para mulheres.
- **female = 0**: para homens.

A categoria codificada como zero é a **categoria de referência**.

8.1. Modelo com uma dummy

O modelo com uma variável binária D_i pode ser escrito como:

$$Y_i = \beta_0 + \beta_1 D_i + u_i$$

Sob a hipótese de média condicional zero do erro:

$$E(Y_i | D_i = 0) = \beta_0$$

$$E(Y_i | D_i = 1) = \beta_0 + \beta_1$$

$$\beta_1 = E(Y_i | D_i = 1) - E(Y_i | D_i = 0)$$

Os elementos representam:

- D_i : variável dummy, que vale 0 ou 1.
- β_0 : média prevista do grupo de referência, codificado como zero.
- β_1 : diferença entre a média prevista do grupo codificado como um e a do grupo zero.
- $\beta_0 + \beta_1$: média prevista para o grupo codificado como um.

Assim, β_1 é a diferença média prevista entre os grupos. No exemplo, a dummy feminino compara valores de gorjeta; a associação observada não prova efeito causal.

8.2. Mais de duas categorias

Em regressões com várias categorias, costuma-se criar dummies para as categorias e deixar uma de fora como referência.

Incluir uma dummy para cada categoria junto com o intercepto cria redundância perfeita. Por isso, a categoria de referência é omitida.

9. Como organizar a leitura de uma regressão

- **Defina a pergunta e as variáveis**: identifique Y , os regressores e as unidades de medida.
- **Interprete condicionalmente**: leia a mudança prevista em Y associada a X , mantendo os demais regressores constantes.

- **Avalie o que o resultado permite concluir:** ajuste não prova causalidade. Confira as hipóteses, variáveis omitidas e erros-padrão antes de interpretar testes e intervalos.